



**Universidade Federal do Amazonas  
Faculdade de Tecnologia - FT  
Programa de Pós-Graduação em Engenharia Elétrica  
- PPGEE**

**Felipe Augusto Souza Guimarães**

**Controle de cadeira de rodas por Leap Motion  
integrada à um Ambiente Inteligente**

Projeto de Qualificação  
apresentado ao curso  
de Mestrado em Engenharia Elétrica, área de concentração Controle e Automação de Sistemas, do Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal do Amazonas.

**Orientador: Prof. Dr. -Ing. Vicente Ferreira de Lucena Junior**

**Manaus  
2019**

**Felipe Augusto Souza Guimarães**

**Controle de cadeira de rodas por Leap Motion  
integrada à um Ambiente Inteligente**

Projeto de Qualificação  
apresentado ao curso  
de Mestrado em Enge-  
nharia Elétrica, área  
de concentração Con-  
trole e Automação de  
Sistemas, do Programa  
de Pós-Graduação em  
Engenharia Elétrica da  
Universidade Federal  
do Amazonas.

**Banca examinadora**

**Prof. Dr. -Ing. Vicente Ferreira de Lucena Junior**

**Prof. Dr. Cícero Ferreira Fernandes Costa Filho**

**Profa. Dra. Marly Guimarães Fernandes Costa**

# Lista de ilustrações

Figura 1 – População com deficiência no Brasil, Censo de 2010. . . . .	7
Figura 2 – Visão geral do processo do sistema [Fonte: autor]. . . . .	13
Figura 3 – Dispositivo Leap Motion [Fonte: Leap Motion for Developers [26]] . . .	14
Figura 4 – Cadeira de rodas motorizada Freedom Lumina. [Fonte: Freedom [1]] .	15
Figura 5 – Diagrama em blocos do sistema proposto. [Fonte: autor] . . . . .	16
Figura 6 – Hiperplano de separação feito pelo SVM [Fonte: Medium [8]] . . . . .	17
Figura 7 – Classificação de um novo valor usando KNN [Fonte: Medium [4]] . . . .	18
Figura 8 – 15 gestos treinados pelo modelo de aprendizagem de máquina . . . . .	19
Figura 9 – Modelo inicial da rede neural convolucional [Fonte: Autor]. . . . .	20
Figura 10 – Acurácia do modelo gerado [Fonte: Autor] . . . . .	20
Figura 11 – Gráfico de perda do modelo gerado [Fonte: Autor]. . . . .	21

# Lista de tabelas

Tabela 1 – Tabela comparativa com os trabalhos relacionados . . . . .	12
Tabela 2 – Cronograma-Ano 1 . . . . .	23
Tabela 3 – Cronograma-Ano 2 - Parte 1 . . . . .	24
Tabela 4 – Cronograma-Ano 2 - Parte 2 . . . . .	25

# Sumário

<b>1</b>	<b>INTRODUÇÃO . . . . .</b>	<b>6</b>
<b>1.1</b>	<b>Contexto e Motivação . . . . .</b>	<b>6</b>
<b>1.2</b>	<b>Objetivos . . . . .</b>	<b>8</b>
1.2.0.1	Objetivo Geral . . . . .	8
1.2.0.2	Objetivos Específicos . . . . .	8
<b>1.3</b>	<b>Trabalhos Relacionados . . . . .</b>	<b>8</b>
<b>2</b>	<b>PROPOSTA . . . . .</b>	<b>13</b>
<b>2.1</b>	<b>Sistema proposto . . . . .</b>	<b>13</b>
<b>2.2</b>	<b>Leap Motion . . . . .</b>	<b>13</b>
<b>2.3</b>	<b>Ambiente Inteligente . . . . .</b>	<b>15</b>
<b>2.4</b>	<b>Cadeira de rodas . . . . .</b>	<b>15</b>
<b>2.5</b>	<b>Controlador . . . . .</b>	<b>16</b>
2.5.1	Aprendizagem de Máquina . . . . .	16
2.5.2	Support Vector Machine (SVM) . . . . .	17
2.5.3	K Nearest Neighbour (KNN) . . . . .	17
2.5.4	Redes Neurais Convolucionais (CNN) . . . . .	18
<b>3</b>	<b>PROJETO DE PESQUISA . . . . .</b>	<b>19</b>
<b>3.1</b>	<b>Aquisição de dados . . . . .</b>	<b>19</b>
<b>3.2</b>	<b>Resultados Iniciais . . . . .</b>	<b>19</b>
<b>4</b>	<b>METODOLOGIA E CRONOGRAMA DE ATIVIDADES . .</b>	<b>22</b>
	<b>Referências . . . . .</b>	<b>26</b>

# 1 Introdução

A paraplegia ocorre quando um indivíduo apresenta uma disfunção muscular ou até mesmo uma lesão em sua medula espinhal traduzindo-se na perda de controle e sensibilidade dos membros inferiores [17], fazendo que o mesmo tenha que utilizar cadeira de rodas por um período indeterminado de tempo para se locomover. A cadeira de rodas tradicional é movida por força humana, que por sua vez gera um grande desgaste físico para os usuários.

Existem diversos graus de deficiência motora e é necessário identificar qual a tecnologia mais apropriada para um usuário específico [9]. Por isso, diversas pesquisas científicas associam graus diferentes de deficiência com equipamentos mais ou menos invasivos. De fato, tecnologias assistivas buscam atender alguma necessidade do usuário. Essa área de pesquisa engloba a utilização de recursos, produtos, metodologias e estratégias, de modo a proporcionar uma melhor qualidade de vida. Tecnologias como eye tracking, head motion e joystick são algumas das quais são usadas como parte da solução para auxílio na locomoção e interação com o ambiente e com os dispositivos utilizados [28][14][27].

Esse trabalho tem por finalidade desenvolver uma tecnologia assistiva que utiliza o Leap Motion como meio de entrada de comandos para a locomoção da cadeira de rodas e para o controle de um ambiente inteligente. O usuário típico terá movimento das mãos e o sistema permitirá que ele tenha a facilidade em comandar uma cadeira de rodas elétrica e atuar sobre um ambiente inteligente e consiga atender suas necessidades, como, por exemplo, acender as luzes, ligar eletrodomésticos e abrir portas, permitindo uma maior independência. O ambiente inteligente terá a habilidade de aprender o contexto e, usando técnicas modernas de inteligência artificial e de aprendizagem de máquina, poderá se antecipar às necessidades do usuário.

Este trabalho está estruturado da seguinte forma, na seção 1.1 descreve-se a motivação desta dissertação, bem como a justificativa para a criação dessa plataforma assistiva; na seção 1.2 são descritos os objetivos gerais e específicos; na seção 2 são mostrados os trabalhos relacionados a esta pesquisa, na seção 3 é descrita a metodologia que é utilizada para realização da plataforma assistiva e, por fim, na seção 4 é mostrado o cronograma de atividades.

## 1.1 Contexto e Motivação

A cadeira de rodas traz certas limitações e dificuldades, muito em função da inadequação das edificações, mobiliários, equipamentos urbanos, espaços, elementos e da própria

cadeira de rodas, no que se refere à manobrabilidade e outros recursos tecnológicos.

Leis e decretos foram elaborados para garantir os direitos das pessoas portadoras de deficiência. Entre eles, a Lei Nº 7.853/89 que define a Política Nacional de Integração da Pessoa Portadora de Deficiência em múltiplos aspectos [7], regulamentada pelo Decreto Nº 3.298/99 que estabelece o respeito, a inclusão social, a não-discriminação, o acesso, o ingresso e a permanência da pessoa portadora de deficiência em todos os serviços oferecidos à comunidade, entre outros princípios [6].

A lei Nº 10.098/00, estabelece normas gerais, critérios básicos e dá outras providências para a promoção da acessibilidade de pessoas portadoras de deficiência ou com mobilidade reduzida, mediante a remoção de barreiras e obstáculos nas vias e nos espaços públicos, no mobiliário urbano, na construção e na reforma de edifícios e nos meios de transporte e comunicação [5].

Apesar da legislação e das normas existentes, as condições do ambiente do usuário de cadeiras de rodas são ainda inadequadas.

De acordo com o Censo de 2010 no Brasil [3] pouco mais de 5% da população possui alguma deficiência motora como é mostrado na Figura 1.



**Figura 1** – População com deficiência no Brasil, Censo de 2010.

Na matéria postada pelo site do Estadão em setembro de 2018 [2], 50% dos cadeirantes sofrem de dores nas mãos, nos pulsos e nos cotovelos devido ao uso da cadeira de rodas [33].

Essa dissertação busca implementar uma tecnologia assistiva capaz de controlar uma cadeira de rodas em um ambiente inteligente, utilizando o Leap Motion como meio de entrada de imagens para reconhecimento de gestos de mãos.

O Leap Motion é um dispositivo cuja a capacidade principal é detectar dedos e movimentos das mãos e gerar coordenadas espaciais que podem ser usadas em desenvolvimen-

tos de jogos de realidade virtual [25]. Devido às suas câmeras de infravermelho, o Leap Motion é uma tecnologia excelente para reconhecer as mãos de um indivíduo independentemente de qualquer fonte de luz, diferente das soluções que utilizam webcams para reconhecer gestos. Além disso, utiliza-se de técnicas modernas de inteligência artificial e de aprendizagem de máquina [15] que permitem ao sistema aprender diversos gestos [13] e associá-los a alguma ação de controle da cadeira de rodas e do ambiente inteligente.

## 1.2 Objetivos

### 1.2.0.1 Objetivo Geral

O objetivo deste trabalho é implementar um sistema capaz de controlar uma cadeira de rodas e um ambiente inteligente a partir de gestos pré-treinados usando uma técnica de aprendizado de máquina supervisionada para o reconhecimento das mãos. Para a coleta de dados de imagens de gestos de mãos, para uso no treino e teste de um modelo de aprendizado de máquina, e como meio de entrada de dados para um modelo de predição será utilizado o dispositivo Leap Motion.

### 1.2.0.2 Objetivos Específicos

1. Implementar um modelo de aprendizado de máquina que reconheça gestos coletados com o Leap Motion.
2. Implementar funcionalidades básicas para acionamento de dispositivos de um ambiente inteligente.
3. Implementar um sistema de acionamento de cadeira de rodas com o Leap Motion.
4. Realizar estudos e comparações com métodos similares de controle de cadeira de rodas.
5. Integrar todos os módulos e avaliar a solução desenvolvida.

## 1.3 Trabalhos Relacionados

Os artigos foram pesquisados na base de dados Google Scholar, utilizando como pergunta base da pesquisa a frase "Wheelchair controled by hand gesture recognition", retornando cerca de 17.700 artigos dos quais foram selecionados apenas 20 artigos para fazer parte do estado da arte, levando-se em conta os critérios de similaridade com o tema proposto, metodologia empregada e relevância. Durante as pesquisas foram encontradas aplicações que utilizam Leap Motion ou algum meio de entrada similar para o controle



da cadeira de rodas. As obras mencionadas utilizam do conceito de controle de cadeira de rodas por gestos, visando atender usuários paraplégicos.

Na obra *Multimodal Wheelchair Control for the Paralyzed People* [24], de Maskeliunas e Simutis, por padrão os modelos de cadeiras de rodas elétricas não atendem usuários que possuem uma capacidade de locomoção altamente limitada, no caso de pessoas tetraplégicas. A proposta do seu sistema Multimodal é permitir que a maior parte dos usuários de cadeiras de rodas seja capaz de utilizá-las por reconhecimento de toque de dedos, reconhecimento de fala e rastreamento de olho. Além disso possibilita ao usuário controlar dispositivos e o ambiente ao seu redor.

Kundu e colegas [21] em sua obra utilizaram unidades de sensores mioelétricos que inclui um eletrodo de bio-potencial, um circuito pré-amplificador, um microcontrolador ATMEGA-8 e uma bateria de 9V, presos ao braço do usuário. Esses sensores controlam uma cadeira omnidirecional com três graus de liberdades de movimentação, permitindo movimentos translacionais e rotacionais. O sistema desenvolvido reconhece sete gestos, com reconhecimento e classificação sendo feito através de extração de características da mão do indivíduo e utilizando um classificador *Dendrogram Support Vector Machine* (DSVM). Os gestos dinâmicos são mapeados para os comandos de movimentação omnidirecional para a navegação da cadeira de rodas. A unidade de medição de inércia é utilizado para calcular o ângulo e a aceleração do pulso, enquanto um gesto está sendo executado. O sistema reconhece sete diferentes gestos básicos para o controle da mobilidade da cadeira de rodas, nomeados frente, trás, esquerda, direita, sentido horário, sentido anti-horário e parada. O algoritmo de reconhecimento e classificação primeiramente faz a diferença entre as atividades estáticas e dinâmicas e automaticamente detecta o início e o fim de um gesto válido com a ajuda de três acelerômetros. Essa diferença entre os estados estáticos e dinâmicos é detectada pela mudança no conjunto de valores fornecidos pelo acelerômetro com as amostras passadas. Para qualquer atividade dinâmica, o desvio padrão do acelerômetro mostra um aumento significativo, enquanto que para gestos estáticos a resposta é pequena. O sistema reconhece que um gesto está sendo executado quando há uma mudança de um gesto estático para um gesto dinâmico. A coleta de características do gesto é feita pelo acelerômetro, que detecta a rotação do pulso e da mão, e pela unidade mioelétrica presa ao antebraço para a coleta de informações dos músculos. Os dados coletados passam por um classificador DSVM e, caso o gesto executado seja reconhecido como um gesto válido, a cadeira se movimenta para a direção reconhecida.

Chang e colegas [11], utilizaram de técnicas de sistemas embarcados, comunicação com ZigBee, reconhecimento de posturas, posicionamento em ambientes internos usando sensores infravermelho e técnicas de processamento de imagens, para auxiliar uma pessoa idosa que necessita do uso da cadeira de rodas para locomoção. Quando a pessoa idosa realiza uma pose válida, a cadeira se move até o local em que a mesma se encontra. Para

o idoso controlar a cadeira, primeiramente ele deve realizar um gesto válido, que no caso pode ser o gesto de repouso, o gesto de chamada ou o gesto de estacionar, em seguida, o kinnect reconhece o gesto executado e informa ao servidor. O servidor por meio de uma interface ZigBee, informa a cadeira a rota que deve seguir até seu destino. Por meio de LED's infravermelho presos ao teto, na forma de uma matriz, é feito o posicionamento em ambiente interno da cadeira de rodas, permitindo que ela vá para frente, para trás, esquerda, direita e realize movimentos na diagonal.

Yashoda [34], desenvolveu a partir de uma cadeira de rodas convencional, uma cadeira capaz de ser comandada por um joystick, por comandos de voz e por gestos usando o Leap Motion. Em sua interface principal, o usuário escolhe qual meio de entrada deseja utilizar. Caso o meio de entrada selecionado seja por voz, ela é captada por um microfone anexado a cadeira de rodas, utilizando a API *Microsoft speech recognition*. A voz reconhecida é convertida em texto. Se o texto for um comando pré-definido, o controlador principal envia a um Arduino a ação a ser executada. Quando for selecionado como meio de entrada gestos, o Leap Motion SDK é utilizado para captar a posição da mão acima do Leap Motion. De maneira bem intuitiva, o usuário pode comandar a cadeira de rodas com os principais comandos de freiar, frente, trás, esquerda e direita. Yashoda utilizou as funções básicas do Leap Motion para fornecer a posição (x,y,z). Com base na posição espacial de captura de mãos que o Leap Motion gera e na delimitação do espaço em duas dimensões, Yashoda conseguiu realizar os comandos básicos para o controle de cadeira de rodas.

Kim-tien e colegas[20], tem uma proposta de cadeira de rodas por reconhecimentos de gestos de mão utilizando uma webcam, para auxiliar paraplégicos e idosos em sua locomoção, exercícios e reabilitação. Para o sistema saber qual gesto está sendo executado pelo usuário, primeiramente, as imagens recebidas pela webcam são convertidas em imagens em escala de cinza, em seguida é utilizado um limiar e filtros para detectar as bordas da imagem, então um filtro gaussiano é utilizado para pré-processamento da imagem para eliminação de ruídos e detalhes indesejados da mão. Cada pixel na imagem é comparado com um valor limiar para detecção das bordas da imagem. Dessa forma uma lista de contornos da imagem é obtida. Kim-Tien utiliza *Freeman Chain code* para representar graficamente os pontos da lista de contornos por uma sequência de segmentos de linhas retas de tamanho e direção especificados. Em seguida é utilizado um algoritmo de Douglas-Peucker para combinar esses pontos pelo método de aproximação de polígonos. A primeira linha do polígono é criada pelos pontos de máxima distância. O terceiro ponto terá a máxima distância da linha criada. Esse processo irá continuar até que a distância entre o ponto e a linha seja menor ou igual a um valor constante especificado. Por fim, é feito um cálculo de ângulo da linha gerada, e com esse ângulo calculado é possível determinar o gesto que está em execução.

Zhang e Luo [35], propuseram em seu trabalho uma cadeira de rodas inteligente ba-

seada em reconhecimento de gestos de mão com uma interface amigável. Geralmente o reconhecimento de gestos de mão pode ser um grande problema devido ao alto grau de liberdade, backgrounds flexíveis e inúmeras condições de luz. Zhang e Luo resolveram esse problema de características com métodos Harr-like e o algoritmo AdaBoost para o treinamento do classificador. O comando de controle da cadeira de rodas foi determinado pela posição da mão na imagem extraída da webcam. Por exemplo, caso a mão permaneça na área central da imagem, a cadeira permanecerá parada, caso a mão permaneça na área do topo da imagem, a cadeira começará a se mover pra frente e assim por diante. Para o treinamento do modelo de classificação foram utilizadas 943 imagens de amostras para identificar o punho e outras 3128 imagens onde o punho não aparece. O modelo treinado identifica se tem um punho ou não na imagem fornecida pela webcam. A biblioteca OpenCV fornece uma posição  $(x,y)$  do punho na imagem. Também é possível na mesma biblioteca delimitar as áreas da imagem e realizar a execução de comandos de acordo com a posição do punho.

Lu [22], desenvolveu em sua pesquisa uma cadeira de rodas inteligente baseada em reconhecimento de gestos, utilizando um acelerômetro de 3 eixos integrado a um microcontrolador a uma unidade Bluetooth. Os sinais capturados passam por um pré-processamento com filtros para eliminar os ruídos indesejados introduzidos pelo ambiente e pela mudança do gesto. Os dados do sensor são normalizados para unificar as diferentes amplitudes do gesto. Quando o dado pré-processado chega ao computador, o mesmo passa por um módulo de segmentação que identifica o início e o fim do gesto utilizando o cálculo da distância euclidiana entre a posição atual com a posição passada. Pelo que se sabe, quando um movimento está em execução, a posição atual difere significativamente da posição passada, ou seja, o valor da distância euclidiana é consideravelmente alto. Baseado nisso, Lu utilizou o vetor de distâncias para segmentar o vetor de dados fornecido pelo acelerômetro. O vetor de dados é quantizado para transformar os dados tri-dimensionais fornecidos pelo sensor em dados unidimensionais utilizando do algoritmo k-means. O vetor quantizado passa por um modelo de Markov para treinamento e, posteriormente, por um método Bayesiano para realizar a predição dos gestos. No treinamento do modelo de Markov, os valores dentro do vetor segmentado e quantizado são utilizados para classificar cada gesto. Com todos os estágios do movimento armazenado, o modelo de Markov determina o gesto que está sendo executado comparando o estado atual com o estado passado da sequência conhecida.

Škraba e colegas [30], no seu trabalho de pesquisa desenvolveram um prototipo de uma cadeira de rodas controlada pelo Leap Motion. O Leap Motion retorna para a cadeira a posição da mão. Dependendo da posição em que a mão se encontra no espaço 2-D gerado pelo Leap Motion, é executado uma ação de movimentação da cadeira, para frente, para trás, para esquerda ou para direita. Škraba utiliza a API padrão do Leap Motion para captar a mão e retornar a posição  $(x,y)$ . Uma interface gráfica usa essa posição  $(x,y)$  para

acionar um controle de movimentação da cadeira de rodas.

Boyali e colegas [10], fizeram um estudo de reconhecimento de gestos e posturas utilizando um método baseado em blocos esparsos e classificação por representação esparsa. Um Leap Motion é usado para a captura da posição espacial da mão esquerda. Foram mapeadas cinco posições que são usadas para comandar uma cadeira de rodas elétrica. No método de blocos esparsos que Boyali e colegas utilizam em seu projeto, dado as amostras coletadas, pode-se assumir que o bloco de valores representa um gesto. Com isso, um dicionário de gestos é formado e classificado por um método bayesiano.

Posada e colegas [29] desenvolveram no LabView um sistema de controle de cadeira de rodas por gestos de mão. O sistema conta com sensores de presença para detecção de escadas e obstáculos e sensores de luz para regulação da iluminação para captação de imagens pela webcam. As imagens capturadas pela webcam passam primeiramente por uma detecção de pele baseada em distribuição de probabilidade para decidir se o pixel pertence a uma pele humana. Logo após a detecção do mão, o gesto é reconhecido por meio de compatibilidade geométrica que extrai o vetor de características que representa cada sinal. A detecção e reconhecimento de gestos e objetos depende inteiramente do ângulo em que se encontra e das condições da fonte de luz. A disposição desses elementos pode afetar a imagem capturada pela webcam.

A Tabela 1, tem por finalidade, comparar todas os trabalhos citados com o trabalho a ser desenvolvido.

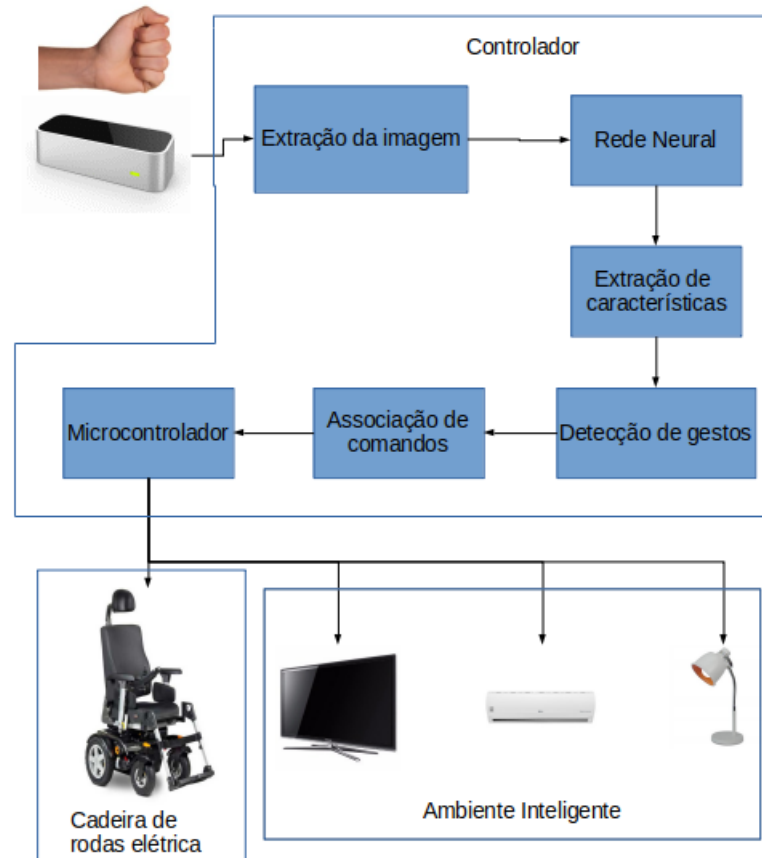
**Tabela 1** – Tabela comparativa com os trabalhos relacionados

	Usa Leap Motion	Aprendizagem de máquina	controle de um ambiente inteligente	redes neurais	controle de cadeira de rodas elétrica	Utiliza mais de uma interface de controle
Boyali	S	N	N	N	S	N
Skraba	S	N	N	N	S	S
Yashoda	S	N	N	N	S	S
Maskelinas	N	N	S	S	S	S
Kundu	N	S	N	S	S	N
Chang	N	N	N	N	S	N
Kim-tien	N	N	N	N	S	N
Zhang	N	S	N	S	S	N
Lu	N	S	N	N	S	N
Posada	N	N	N	N	S	N
Sistema Proposto	S	S	S	S	S	N

## 2 Proposta

### 2.1 Sistema proposto

A proposta desta dissertação é desenvolver um sistema de acionamento de uma cadeira de rodas elétrica integrado a um ambiente inteligente, empregando um software baseado em computador que implementa um algoritmo de aprendizado de máquina para reconhecimento de gestos de mão que são coletados por um dispositivo conhecido por Leap Motion. A Figura 2 mostra a versão do sistema proposto.




**Figura 2** – Visão geral do processo do sistema [Fonte: autor].

### 2.2 Leap Motion

Leap Motion é um dispositivo que rastreia o movimento das mãos e dedos com alta precisão e com alta acuracidade, muito utilizado em aplicações de realidade virtual e realidade aumentada para treinamento industrial, reabilitação e educação [32].

O Leap Motion, mostrado na Figura 3, possui duas cameras e três LEDs infravermelhos dentro dele, que podem detectar a luz infravermelha. Devido às suas duas câmeras, ele cria uma imagem estéreo em escala de cinza a partir dos dados de luz infravermelha, o que o torna independente do nível de iluminação ambiente, já que ele capta o calor das mãos. O dispositivo usa algoritmos para calcular os dados da mão a partir dos dados brutos do sensor. Esses dados brutos são compostos de valores de brilho infravermelho e dados de calibração para corrigir distorções das lentes. Seu alcance de rastreamento de movimento está entre 2,5 cm e 60 cm [18]. O Leap Motion pode tanto gerar a imagem em infravermelho da mão do usuário como também um vetor de pontos  $(x,y,z)$  de posicionamento dos principais elementos da mão, como a posição da ponta dos dedos e do centro da palma da mão. Essas posições  $(x,y,z)$  da mão podem ser usadas para montar um conjunto de dados contendo informações das distâncias entre os dedos, das distâncias dos dedos à palma da mão e dos ângulos entre os dedos, como mencionado no artigo de Stinghen e colegas [31], em que foi montado um conjunto de dados de 10 gestos com as posições  $(x,y,z)$  das mãos de 6 voluntários, perfazendo um total de 1200 amostras para realizar um estudo comparativo entre as técnicas SVM, KNN e Árvores de Decisão. Mapari e Kharati [23] em sua obra utilizam um conjunto de dados da linguagem de sinais americano capturados pelo Leap Motion, composto de distâncias euclidianas das pontas dos dedos com a palma da mão e entre as pontas dos dedos, para treinar uma rede neural de multicamadas para reconhecimento de gestos.

Nesse projeto de pesquisa o Leap Motion será utilizado para montar dois conjuntos de dados, sendo um de imagens infra-vermelho da mão do usuário e o outro contendo as distâncias euclidianas das posições  $(x,y,z)$  fornecidas pela API do Leap Motion. Os conjuntos de dados terão um total de 15 gestos pré-definidos que serão armazenados e classificados adequadamente e serão usados para controle de dispositivos integrados.



**Figura 3** – Dispositivo Leap Motion [Fonte: Leap Motion for Developers [26]]

## 2.3 Ambiente Inteligente

Um ambiente dito inteligente é formado por dispositivos convencionais, como lâmpadas, luminárias, aparelhos de ar-condicionado, aparelho de televisão e portas com trancas elétricas, que podem ser gerenciados remotamente pelo usuário. Nesse trabalho propõe-se usar uma sala do CETELI como referência, em que será possível controlar a ligação de luminárias e ar-condicionado via o sistema instalado na controladora da cadeira de rodas.

## 2.4 Cadeira de rodas

Uma cadeira de rodas elétrica é impulsionada basicamente por motores e alimentada por baterias. A primeira cadeira de rodas elétrica apareceu durante a primeira guerra mundial, quando um mecanismo foi adicionado a uma cadeira manual [16].

Será utilizada a cadeira de rodas elétrica Freedom Lumina Motorizada 20, mostrada na Figura 4. A cadeira de rodas motorizada Freedom Lumina oferece pedaleiras removíveis (swing-away), com o sistema opcional articulado, o que facilita o transporte e o armazenamento. O chassi é fabricado em duralumínio tratado termicamente para melhor resistência mecânica, resistência à corrosão e intempéries. Este modelo conta com chassi monobloco com suspensão traseira e assento combinado com o sistema de garfo com suspensão, ambos com tecnologia em poliuretano, proporcionando um andar macio em terreno acidentado com mais conforto [1].

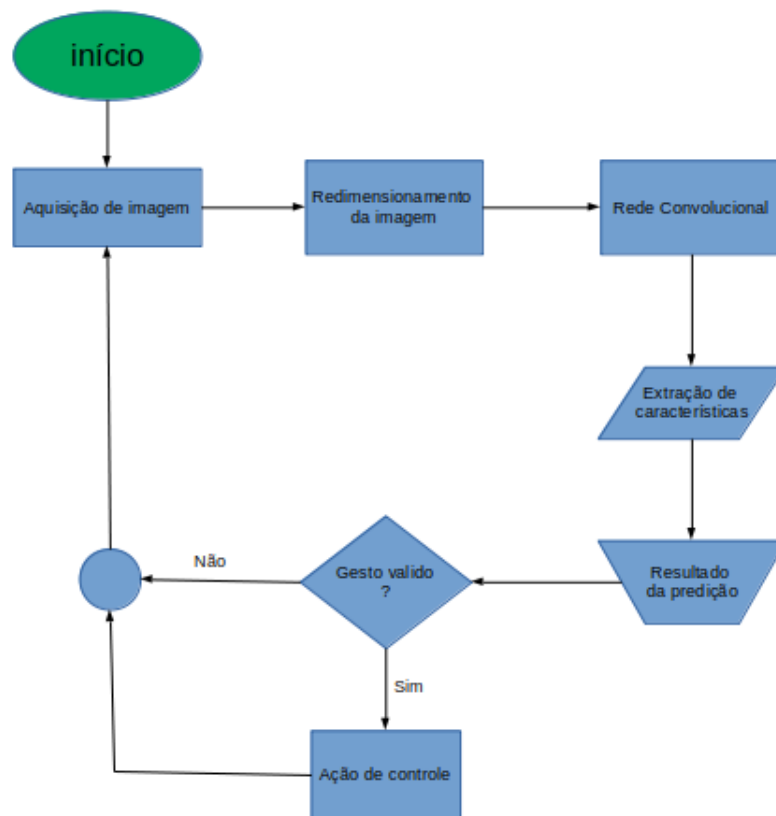


**Figura 4** – Cadeira de rodas motorizada Freedom Lumina. [Fonte: Freedom [1]]

## 2.5 Controlador

Este bloco será constituído basicamente por um computador rodando uma aplicação Python responsável por executar o algoritmo de reconhecimento de gestos, mostrado na Figura 5.

A aplicação recebe as imagens geradas pelo Leap Motion e as redimensiona, de forma que sejam aceitas na entrada da rede neural. A rede neural de convolução passa filtros ao longo da imagem em todas as suas camadas de convolução e extrai características. O vetor de características gerado passa pela camada de saída da rede e retorna o resultado da predição. Se o resultado for um gesto válido, é gerada uma ação de controle na cadeira de rodas elétrica ou no ambiente inteligente.



**Figura 5** – Diagrama em blocos do sistema proposto. [Fonte: autor]

### 2.5.1 Aprendizagem de Máquina

A área de aprendizagem de máquina possibilita ao computador aprender tarefas específicas como reconhecer caracteres, diagnosticar pessoas com doenças severas, classificar tipos de vinho, separar matérias de acordo com a qualidade do material, etc. Essas e muitas outras aplicações deixam evidente o quanto a aprendizagem de máquina pode ser útil




para resolver problemas diários e ajudar especialistas na tomada de decisão [15]. A aprendizagem de máquina consiste de diversas técnicas que dão a habilidade ao computador para aprender um certo padrão a partir de um conjunto de dados pré-selecionados [19]. Sistemas de aprendizagem de máquina podem ser classificados de acordo com o tipo de conjunto de dados e com o tipo de controle (supervisionado ou não supervisionado ou semi-supervisionado) usado durante o treinamento.

Neste projeto de pesquisa serão abordadas técnicas de aprendizagem supervisionada e, a partir de um estudo comparativo, será escolhida a melhor dentre elas, usando a métrica denominada de acurácia. Dentre as técnicas de aprendizagem de máquina, vão ser estudadas as técnicas SVM, KNN e Redes Neurais de Convolução.

### 2.5.2 Support Vector Machine (SVM)


A técnica SVM utiliza um conjunto de dados composto por um par de atributos (X,Y) para traçar um hiperplano de separação para classificar os novos dados de entrada com base na fronteira de decisão traçada [12].



**Figura 6** – Hiperplano de separação feito pelo SVM [Fonte: Medium [8]]

### 2.5.3 K Nearest Neighbour (KNN)

Esse método é conhecido por sua simplicidade, fácil interpretação e baixo custo computacional. Essa técnica basicamente armazena os valores que são disponibilizados e categorizados e os próximos valores de entrada são classificados com base no cálculo de distância dos pontos mais próximos [12].



**Figura 7** – Classificação de um novo valor usando KNN [Fonte: Medium [4]]

#### 2.5.4 Redes Neurais Convolucionais (CNN)


Redes convolucionais são geralmente usadas em aplicações de visão computacional, na área de reconhecimento de objetos em imagens ou vídeos. Redes convolucionais possuem filtros, que extraem diferentes aspectos ou características da imagem para aprender e realizar o processo de classificação, a partir da amostra fornecida.

Inicialmente a imagem passa pelas camadas convolucionais. Sendo processada por convoluções e comprimida para obter uma informação relevante. Cada vez que a imagem passa por uma convolução, a mesma pode perder alguma informação, então a imagem passa por uma camada de *Pooling* para reter a informação extraída pela convolução. Por fim, a imagem passa pela camada de saída com uma função de ativação para ser classificada.

## 3 Projeto de pesquisa

### 3.1 Aquisição de dados

Foi utilizado um conjunto de dados de imagens coletadas com o Leap Motion. O conjunto de dados possui 54.000 amostras divididas em 15 gestos, feitos por 15 pessoas diferentes, como ilustrado na Figura 8. Cada gesto será associado a um comando de ação do controlador.




**Figura 8** – 15 gestos treinados pelo modelo de aprendizagem de máquina

### 3.2 Resultados Iniciais


Foi implementada inicialmente uma rede neural convolucional, com uma camada de entrada recebendo uma imagem de tamanho de 200x200 em escala de cinza, com três camadas convolucionais com suas camadas de *Pooling* e uma camada de saída para prever 15 gestos. Esta rede é ilustrada na Figura 9, que corresponde ao modelo inicial, que será utilizado para traduzir os gestos das imagens coletadas pelo Leap Motion em comandos. O modelo convolucional, treinado utilizando o framework Keras, obteve uma acurácia de 83 % após 10 épocas, o que é mostrado na Figura 10. Na Figura 11 é mostrado o gráfico de erro médio quadrático (perdas) calculado do conjunto de teste. Observa-se que esse

erro diminui com o número de épocas. Se esse erro aumentasse indicaria que a rede estaria começando a aprender com os ruídos do conjunto de treino, o que apontaria uma condição de overfitting.


O termo época corresponde ao número de vezes que se submete o modelo a testes e a treinamento, usando um conjunto de imagens pré-definidas e distintas. Observa-se que quanto mais vezes passamos esse conjunto de imagens pelo modelo (que corresponde ao número de épocas) o desempenho melhora. Em ambos os gráficos está indicado que o modelo não sofreu overfitting e conseguiu generalizar e aprender com os dados passados no treino.



**Figura 9** – Modelo inicial da rede neural convolucional [Fonte: Autor].



**Figura 10** – Acurácia do modelo gerado [Fonte: Autor]



**Figura 11** – Gráfico de perda do modelo gerado [Fonte: Autor].

## 4 Metodologia e Cronograma de Atividades

A metodologia empregada para se alcançar todos os objetivos específicos é composta dos seguintes passos:

Uma revisão bibliográfica sobre o estado da arte de controle de cadeiras de rodas e de ambientes inteligentes controlados por Leap Motion. Esta revisão serve de base para alcançar os objetivos específicos (1), (2) e (3).

Uma revisão bibliográfica sobre o estado da arte em técnicas de aprendizagem de máquina para reconhecimento de gestos. Esta revisão serve de base para se alcançar os objetivos específicos (1) e (4). As técnicas de aprendizagem de máquina estudadas serão implementadas e submetidas a testes de desempenho e acurácia, para se decidir qual o melhor modelo.

Para o objetivo específico (4) e (5) pretende-se comparar o desempenho da cadeira de rodas e do ambiente inteligente controlado por um Leap Motion com os trabalhos equivalentes. É possível que outros métodos possam ser implementados para comparações.

Todas as comparações serão realizadas através de inúmeros testes de reconhecimento de gestos treinados para controle da cadeira de rodas e acionamento do ambiente inteligente no modelo de aprendizagem de máquina escolhido.

**Tabela 2** – Cronograma-Ano 1

Meta	Atividades	1	2	3	4	5	6	7	8	9	10	11	12
Integralização dos créditos	Disciplina 1: Sistemas Lineares: 7.0	X	X	X	X	X	X						
	Disciplina 2: Fundamentos Cyber-Physical System: 9.0	X	X	X	X	X	X						
	Disciplina 3: Tópicos em engenharia de software: 8.5							X	X	X	X	X	X
	Disciplina 4: Rede de sensores sem fio e internet das coisas: 8.25							X	X	X	X	X	X
Revisão bibliográfica	Revisão bibliográfica de técnicas de controle de cadeira de rodas por gestos de mão							X	X	X	X	X	X
	Revisão bibliográfica de técnicas de aprendizagem de máquina para reconhecimento de gestos de mão							X	X	X	X	X	X

**Tabela 3 – Cronograma-Ano 2 - Parte 1**

Meta	Atividade	1	2	3	4	5	6	7	8	9	10	11	12	1	2	3
Integralização dos créditos	Disciplina 5: Aprendizagem de máquinas e mineração de dados: 8.3	X	X	X	X	X	X									
	Disciplina 6: Probabilidade e processos estocásticos : Cursando							X	X	X	X	X	X			
Qualificação	Redação do projeto e qualificação					X	X	X	X	X						
Desenvolvimento do projeto de pesquisa	Implementação de técnicas de Aprendizagem de máquinas para reconhecimento de gestos de mão utilizando o Leap Motion	X	X	X	X	X	X	X								
	Estudo de Comparação das técnicas utilizadas						X	X	X	X	X					
	Teste de eficiência do modelo						X	X	X	X	X					
	Implementação de um ambiente inteligente controlado por um modelo de aprendizagem de máquina que reconhece gestos de mão									X	X					
	Realizar testes com o ambiente inteligente											X				
	Implementar um sistema de controle de cadeira de rodas											X	X			
	Integração do sistema												X			
	Realização de testes no sistema completo												X			





# Referências

- [1] Cadeira de rodas elétrica freedom lumina motorizada 20. <http://www.freedom.ind.br/produto/saude/cadeiras-de-rodas-motorizadas/freedom-lumina-motorizada/>. Acessado em 15-08-2019.
- [2] 50% dos cadeirantes têm dores freqüentes. <https://emails.estadao.com.br/noticias/geral,50-dos-cadeirantes-tem-dores-frequentes,242409>. Acessado em 24-06-2019.
- [3] No brasil, 9 em cada 10 cadeirantes dizem que uso de cadeira de rodas já trouxe problemas no trabalho, diz pesquisa. <https://g1.globo.com/economia/concursos-e-emprego/noticia/2018/08/08/no-brasil-9-em-cada-10-pessoas-dizem-que-uso-de-cadeira-de-rodas-ja-trouxe-problemas-no-trabalho-diz-pesquisa.ghtml>. Acessado em 24-06-2019.
- [4] k nearest neighbor classifier ( knn )-machine learning algorithms. URL <https://medium.com/@equipintelligence/k-nearest-neighbor-classifier-knn-machine-learning-algorithms-ed62feb86582>. Acessado em 15-08-2019.
- [5] Brasil. lei n. 10.098, de 19 de dezembro de 2000. estabelece normas gerais e critérios básicos para a promoção da acessibilidade das pessoas portadoras de deficiência ou com mobilidade reduzida, e dá outras providências. [http://www.mj.gov.br/sedh/ct/corde/dpdh/legis1/doc\\_legis2.asp?id=198](http://www.mj.gov.br/sedh/ct/corde/dpdh/legis1/doc_legis2.asp?id=198), . Acessado em 15-08-2019.
- [6] Brasil. decreto n. 3.298, de 20 de dezembro de 1999. regulamenta a lei no 7.853, de 24 de outubro de 1989, dispõe sobre a política nacional para a integração da pessoa portadora de deficiência, consolida as normas de proteção e dá outras providências. [https://www.planalto.gov.br/ccivil\\_03/decreto/D3298.htm](https://www.planalto.gov.br/ccivil_03/decreto/D3298.htm), . Acessado em 15-08-2019.
- [7] Brasil. lei n. 7.853, de 24 de outubro de 1989. dispõe sobre o apoio às pessoas portadoras de deficiência, sua integração social, sobre a coordenadoria nacional para integração da pessoa portadora de deficiência – corde, institui a tutela jurisdicional de interesses coletivos ou difusos dessas pessoas, disciplina a atuação do ministério público, define crimes, e dá outras providências. <http://www.mj.gov.br/sedh/ct/corde/dpdh/corde/lei7853.asp>, . Acessado em 15-08-2019.
- [8] Chapter 3: Support vector machine with math. URL <https://medium.com/deep-math-machine-learning-ai/>

- chapter-3-support-vector-machine-with-math-47d6193c82be. Acessado em 15-08-2019.
- [9] C. Abbott. Defining assistive technologies-a discussion. *Journal of Assistive Technologies*, 1(1):6–9, 2007. doi: 10.1108/17549450200700002.
- [10] A. Boyali, N. Hashimoto, and O. Matsumato. \*\*hand posture control of a robotic wheelchair using a leap motion sensor and block sparse representation based classification. In *SMART 2014, The Third International Conference on Smart Systems, Devices and Technologies*, pages 20–25, 2014.
- [11] C.-L. Chang, C.-C. Chen, C.-Y. Chen, and B.-S. Lin. Kinect-based powered wheelchair control system. In *2013 4th International Conference on Intelligent Systems, Modelling and Simulation*, pages 186–189. IEEE, 2013. doi: 10.1109/ISMS.2013.74.
- [12] R. Choudhary and H. K. Gianey. Comprehensive review on supervised machine learning algorithms. In *2017 International Conference on Machine Learning and Data Science (MLDS)*, pages 37–43. IEEE, 2017. doi: 10.1109/MLDS.2017.11.
- [13] C.-H. Chuan, E. Regina, and C. Guardino. American sign language recognition using leap motion sensor. In *2014 13th International Conference on Machine Learning and Applications*, pages 541–544. IEEE, 2014. doi: 10.1109/ICMLA.2014.110.
- [14] M. Cognolato, M. Atzori, and H. Müller. Head-mounted eye gaze tracking devices: An overview of modern devices and recent advances. *Journal of rehabilitation and assistive technologies engineering*, 5:2055668318773991, 2018. doi: 10.1177/2055668318773991.
- [15] R. F. de Mello and M. A. Ponti. A brief review on machine learning. In *Machine Learning*, pages 1–74. Springer, 2018. doi: 10.1007/978-3-319-94989-5\_1.
- [16] DiGiovine. Wheelchair, eletric in: Encyclopedia of disability. 2006. doi: 10.4135/9781412950510.n822.
- [17] M. Dijkers. Quality of life of individuals with spinal cord injury: a review of conceptualization, measurement, and research findings. *Journal of rehabilitation research and development*, 42(3):87, 2005. doi: 10.1682/jrrd.2004.08.0100.
- [18] T. Guzsvinecz, V. Szucs, and C. Sik-Lanyi. Suitability of the kinect sensor and leap motion controller—a literature review. *Sensors*, 19(5):1072, 2019. doi: 10.3390/s19051072.
- [19] A. Géron. In *Hands-On Machine Learning with Scikit-Learn Tensorflow*, volume First Edition. O’Reilly Media, 2017.

- [20] N. Kim-Tien, N. Truong-Thinh, and T. D. Cuong. A method for controlling wheelchair using hand gesture recognition. In *Robot Intelligence Technology and Applications 2012*, pages 961–970. Springer, 2013. doi: 10.1007/978-3-642-37374-9\_93.
- [21] A. S. Kundu, O. Mazumder, P. K. Lenka, and S. Bhaumik. Hand gesture recognition based omnidirectional wheelchair control using imu and emg sensors. *Journal of Intelligent & Robotic Systems*, 91(3-4):529–541, 2018. doi: 10.1007/s10846-017-0725-0.
- [22] T. Lu. A motion control method of intelligent wheelchair based on hand gesture recognition. In *2013 IEEE 8th Conference on Industrial Electronics and Applications (ICIEA)*, pages 957–962. IEEE, 2013. doi: 10.1109/ICIEA.2013.6566505.
- [23] R. B. Mapari and G. Kharat. American static signs recognition using leap motion sensor. In *Proceedings of the Second International Conference on Information and Communication Technology for Competitive Strategies*, page 67. ACM, 2016. doi: 10.1145/2905055.2905125.
- [24] R. Maskeliunas and R. Simutis. Multimodal wheelchair control for the paralyzed people/multimodalinis paralyziuotuju vezimelio valdymas. *Elektronika ir Elektrotechnika*, (5 (111)):81–85, 2011. ISSN 1392–1215.
- [25] A. Nandy. In *Leap Motion for Developers*. Apress, 2016. doi: 10.1007/978-1-4842-2550-9.
- [26] A. Nandy. *Leap Motion for Developers*. Springer, 2016. doi: 10.1007/978-1-4842-2550-9.
- [27] M. Oppenheim. Headbanger: controlling switchable software with head gesture. *Journal of Assistive Technologies*, 10(1):2–10, 2016. doi: 10.1108/jat-04-2015-0015.
- [28] M. Porta. A study on text entry methods based on eye gestures. *Journal of Assistive Technologies*, 9(1):48–67, 2015. doi: 10.1108/jat-12-2013-0037.
- [29] R. Posada-Gomez, L. Sanchez-Medel, G. A. Hernandez, A. Martinez-Sibaja, A. Aguilar-Laserre, and L. Leija-Salas. A hands gesture system of control for an intelligent wheelchair. In *2007 4th International Conference on Electrical and Electronics Engineering*, pages 68–71. IEEE, 2007. doi: 10.1109/ICEEE.2007.4344975.
- [30] A. Škraba, A. Koložvari, D. Kofjač, and R. Stojanović. Wheelchair maneuvering using leap motion controller and cloud based speech control: Prototype realization. In *2015 4th Mediterranean Conference on Embedded Computing (MECO)*, pages 391–394. IEEE, 2015. doi: 10.1109/MECO.2015.7181952.

- 
- [31] I. A. Stinghen Filho, B. B. Gatto, J. L. d. S. Pio, E. N. Chen, J. M. Junior, and R. Barboza. Gesture recognition using leap motion: A machine learning-based controller interface. ISSN 2179-2259.
- [32] E. Tarakci, N. Arman, D. Tarakci, and O. Kasapcopur. Leap motion controller-based training for upper extremity rehabilitation in children and adolescents with physical disabilities: A randomized controlled trial. *Journal of Hand Therapy*, 2019. doi: 10.1016/j.jht.2019.03.012.
- [33] O. Ustunkaya, A. O. Edeer, H. Donat, and N. Yozbatiran. Shoulder pain, functional capacity and quality of life in professional wheelchair basketball players and non-athlete wheelchair users. *The Pain Clinic*, 19(2):71–76, 2007. doi: 10.1179/016911107x268657.
- [34] H. Yashoda, A. Piumal, P. Polgahapitiya, M. Mubeen, M. Muthugala, and A. Jayasekara. Design and development of a smart wheelchair with multiple control interfaces. In *2018 Moratuwa Engineering Research Conference (MERCon)*, pages 324–329. IEEE, 2018. doi: 10.1109/MERCon.2018.8421945.
- [35] Y. Zhang, J. Zhang, and Y. Luo. A novel intelligent wheelchair control system based on hand gesture recognition. In *The 2011 IEEE/ICME International Conference on Complex Medical Engineering*, pages 334–339. IEEE, 2011. doi: 10.1109/ICCME.2011.5876761.